



Univerzitet "Džemal Bijedić" u Mostaru
Fakultet informacijskih tehnologija

Recommender sistem dokumentacija

PREDMET: RAZVOJ SOFTVERA 2
PREDMET: RAZVOJ SOFTVERA 2

PROFESOR: ELMIR BABOVIĆ
ISMIHANA MEĐEDOVIĆ

Sistem preporuke

U prijavi teme naveli smo da ćemo koristiti Colaborative filtering kako bi korisnicima preporučio recepte na temelju njihovih prethodnih interakcija sa receptima (kao što su lajkovani recepti ili dodani među omiljene). Colaborative filtering je metoda koja se oslanja na ponašanje korisnika kako bi napravila predikcije o tome koji bi se recept mogao svidjeti korisnicima na osnovu njihovih sličnosti s drugim korisnicima.

Recommendeder sistem implementiran u ovom projektu temelji se na kolaborativnom filtriranju koristeći „matrix factorization“. Sistem predviđa najrelevantnije recepte za određenog korisnika na osnovu prošlih interakcija, uključujući lajkove i omiljene recepte.

Koristili smo ML.Net za obuku modela i predviđanje, pri čemu je „matrix factorization“ primarni algoritam preporuke.

Sistem koristi podatke o interakcijama korisnika s receptima, pri čemu korisnici označavaju recepte kao "lajkane" (ocjena = 1) ili "omiljene" (ocjena = 3). Ove interakcije služe za obuku modela preporuka.

Na osnovu korisničkog ID-a, sistem predviđa ocjene za sve recepte s kojima korisnik još nije imao interakciju, rangirajući ih po relevantnosti.

Prvo smo prikupljali podatke o korisnicima koji su lajkovali ili označili recept kao omiljeni. Podaci se učitavaju iz tabele Lajkovis i OmiljeniRecepts i koriste se za obučavanje modela. Ukoliko nema interakcija funkcija vraća prazan popis.

MatrixFactorizationTrainer.Options: Definiraju se opcije za algoritam Matrix Factorization, uključujući parametre kao što su:

- MatrixColumnIndexColumnName: Kolona koja predstavlja korisnički ID.
- MatrixRowIndexColumnName: Kolona koja predstavlja ID recepta.
- LabelColumnName: Kolona koja označava ocjenu (rating) korisnika za recept.
- LossFunction: Korištenje SquareLossOneClass kao funkcije gubitka.
- Alpha, Lambda, NumberOfIterations: Parametri koji kontroliraju kako model uči iz podataka.

Zatim smo prikupljali sve recepte za koje korisnik nije već dao interakciju (nije lajkovao ili označio kao omiljen).

Za svaki recept koji korisnik još nije ocijenio, koristi se obučeni model da bi se predvidjela ocjena za tog korisnika i recept. Predviđanje se vrši pomoću CreatePredictionEngine metode koja uzima korisnički ID i ID recepta, a zatim predviđa Score.

Rezultati se sortiraju po predviđenoj ocjeni (veća ocjena znači bolja preporuka), a zatim se vraća prvih 4 recepta kao preporučeni.

Putanju i printscreen source code-a glavne logike recommender sistema.

Putanja:

eRecipes\Recipes\Service\ReceptRecommender.cs

Putanja na githubu:

<https://github.com/Islihana13/eRecipes/blob/main/eRecipes/Recipes.Service/ReceptRecommender.cs>

```
16 public ReceptRecommender(RecipesContext context)
17 {
18     _context = context;
19 }
20
21 public List<Recept> Recommend(int korisnikId)
22 {
23     lock (isLocked)
24     {
25         var interakcije = _context.Lajkovi
26             .Select(x => new UserItemEntry
27             {
28                 UserId = (uint)x.KorisnikId,
29                 ItemId = (uint)x.ReceptId,
30                 Rating = 1
31             })
32             .Union(_context.OmljeniRecepts
33                 .Select(x => new UserItemEntry
34                 {
35                     UserId = (uint)x.KorisnikId,
36                     ItemId = (uint)x.ReceptId,
37                     Rating = 3
38                 })
39                 .ToList());
40
41         if (interakcije.Count == 0)
42         {
43             return new List<Recept>();
44         }
45
46         var trainData = _context.Data.LoadFromEnumerable(interakcije);
47
48         var options = new MatrixFactorizationTrainer.Options
49         {
50             MatrixColumnIndexColumnName = nameof(UserItemEntry.UserId),
51             MatrixRowIndexColumnName = nameof(UserItemEntry.ItemId),
52             LabelColumnName = "Rating",
53             LossFunction = MatrixFactorizationTrainer.LossFunctionType.SquareLossOneClass,
54             Alpha = 0.01,
55             Lambda = 0.025,
56             NumberOfIterations = 100,
57             C = 0.00001
58         };
59
60         var estimator = _context.Recommendation().Trainers.MatrixFactorization(options);
61         model = estimator.Fit(trainData);
62     }
63
64     var sviRecepti = _context.Recepts
65         .Where(r => !_context.Lajkovi.Any(l => l.KorisnikId == korisnikId && l.ReceptId == r.ReceptId) &&
66             !_context.OmljeniRecepts.Any(o => o.KorisnikId == korisnikId && o.ReceptId == r.ReceptId))
67         .ToList();
68
69     var predictionResult = new List<Tuple<Recept, float>>();
70
71     foreach (var recept in sviRecepti)
72     {
73         var predictionEngine = _context.Model.CreatePredictionEngine<UserItemEntry, UserBasedPrediction>(model);
74         var prediction = predictionEngine.Predict(new UserItemEntry
75         {
76             UserId = (uint)korisnikId,
77             ItemId = (uint)recept.ReceptId
78         });
79
80         predictionResult.Add(new Tuple<Recept, float>(recept, prediction.Score));
81     }
82
83     return predictionResult.OrderByDescending(x => x.Item2).Select(y => y.Item1).Take(4).ToList();
84 }
85
```

Slika 1.: Printscreen source code-a glavne logike recommender sistema

Putanju i printscreen iz pokrenute aplikacije gdje se prikazuju preporuke.


Putanja:

eRecipes\UI\erecipes_mobile\lib\screens\recipe_list_screen.dart

Putanja na github-u:

https://github.com/Islihana13/eRecipes/blob/main/eRecipes/UI/erecipes_mobile/lib/screens/recipe_list_screen.dart

Na početnoj stranici ispod liste recepata, stoji tekst „Preporučeni recepti:“ ispod tog teksta stoji lista od 4 recepta. Svaki recept ima sliku, naslov, opis i dugme za pregled detalja recepta. Ukoliko je recept zaključan može vidjeti samo sliku, naslov i opis ali nema mogućnost klika na dugme pregled recepta.



Slika 2.: Printscreen iz pokrenute aplikacije gdje se prikazuju preporuke